

XPU-OJ 评测日志与结果文件（赛题一：Fused MoE GEMM）

1. 最终提交（v432）

- 提交号：135985 状态：Accepted 得分：78.67 timeUsed：17.535 s
- 提交时间：2026-09-02；XPU-OJ 账号：muxi2026C1050

SPJ Report — Testcase #1 (experts=16, hidden=2048, intermediate=8192, total_tokens=2272)

Baseline:	11.251000	ms
User kernel:	2.789000	ms
Speedup vs base:	4.034	x
Score ratio:	0.801353	(80.14%)
Display score:	80	/ 100
Pass:	OK	

SPJ Report — Testcase #2 (experts=32, hidden=7168, intermediate=2048, total_tokens=4544)

Baseline:	18.610000	ms
User kernel:	5.065000	ms
Speedup vs base:	3.674	x
Score ratio:	0.786061	(78.61%)
Display score:	78	/ 100
Pass:	OK	

SPJ Report — Testcase #3 (experts=64, hidden=7168, intermediate=2048, total_tokens=9088)

Baseline:	35.875000	ms
User kernel:	9.681000	ms
Speedup vs base:	3.706	x
Score ratio:	0.787492	(78.75%)
Display score:	78	/ 100
Pass:	OK	

评测环境：XPU-OJ 标准环境（PyTorch 2.8.0+metax 3.7.1.5 / TileLang 0.1.10+cuda.gitf549117c / Python 3.12 / C500 GPU）。计时方式：
warmup 10 次 + 100 次迭代取平均，baseline 固定复用。

2. 提交历史摘要（关键版本）

提交号	版本	状态	得分	说明
126390	v282	Accepted	76.67	双 kernel 基础架构 (A-shared、融合 SwiGLU、column swizzle)
132574	v380	Accepted	77.00	+ safe-memory legalize 关闭 + vec256 关闭
133078	v386	Accepted	77.33	+ Stage2 满块无分支 epilogue
134755	v404	Accepted	78.00	+ hidden7168 Stage1 Down 预取、分派重构
135985	v432	Accepted	78.67	+ enable_fast_math / lower_ldgstg_predicated / case1 分派全开

3. 本地 C500 基准数据（复现记录）

环境：C500 GPU、MACA 3.7.x、tilelang-metax v0.1.10、PyTorch 2.8.0+metax、Python 3.12。

计时：CUDA event, warmup 10 + 100 iters 平均；正确性：fp32 参考实现逐元素对照

(rtol=atol=0.05)。

版本	case1 (ms)	case2 (ms)	case3 (ms)	正确性
v432（最终）	2.778— 2.784	5.728— 5.816	8.993— 9.096	32/32 随机分布 seed 通过
历史基线（官方模板改造前）	—	—	—	A-shared 改造前吞吐 26.8 TFLOPS → 改造后 87 TFLOPS

正确性压力测试 (race_stress2 / race_loop)：随机 expert 尺寸分布 × 随机数据

seed, case1 20 seed、case2 6 seed、case3 6 seed，每 seed 3 次重复，

0 失败、0 NaN（验证 padding/尾块/工作区复用的安全性）。

4. 关键性能数据（Stage 拆分，CUDA event）

case	Stage1	Stage2	口径
case1	1.900 ms	1.090 ms	Stage1 ≈108 TFLOPS (计算 roofline ~94%)
case2	3.744 ms	2.078 ms	带宽 ~1.12 TB/s
case3	5.675 ms	3.338 ms	Stage2 ≈1.30 TB/s (d2d copy 带宽 1.44 TB/s 的 90%)

5. 完整实验日志

完整优化过程（45+ 变体、十个优化维度的全部实验数据与机制分析）见随包提交的

`实验日志\_OPTIMIZATION\_LOG.md` 与 GitHub 仓库

`William7743/muxi\_race` (PROGRESS.md + xpuoj_data/OPTIMIZATION_LOG.md)。